



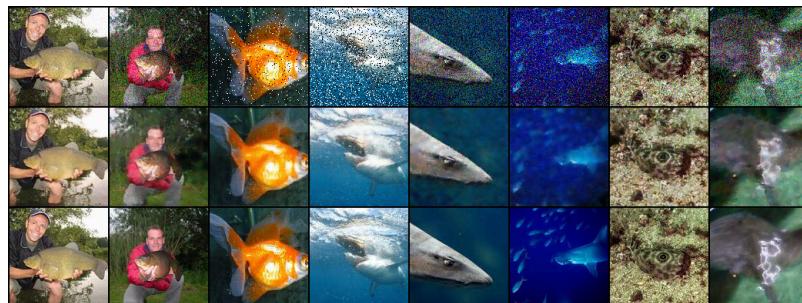
Projet débruitage - Compte rendu semaine du 1/12

Viguier Killian

Wang Xihao

M2 IMAGINE
Faculté des Sciences
Université de Montpellier

8 Décembre 2025



Résumé

Cette semaine, nous avons modifié notre dataset suite à une erreur commise lors de l'attribution du bruit aux images puis nous avons fusionné l'ensemble des types de bruits en un seul modèle. Nous avons également continué de tester de nouvelles manières d'utiliser le GAN pour améliorer nos résultats.

1 Modifications du dataset

1.1 Correction du bruit équivalent

Lors des précédentes semaines, nous avions créé le bruit des images par nous même avec un code modifiant les valeurs des pixels aléatoirement. Nous avons constaté lors de nos tests cette semaine que les seeds utilisées pour la création des bruits étaient identiques pour chaque image, ce qui pose problème car notre modèle n'apprenait donc qu'une seule configuration de bruit pour toutes les images d'un type.



Fig. 1. – Exemple de valeurs de pixels sur une même zone. Les images zoomées du bas correspondent à leur image d'origine en haut.

On peut voir dans l'exemple que le même paterne de couleur est utilisé pour les deux images. Pour régler ce problème, il nous a suffit d'utiliser le numéro de l'image en tant que seed pour le bruit aléatoire. Ainsi, chacune des images possède son propre bruit unique.



Fig. 2. – Exemple de valeurs de pixels sur une même zone. Le paterné ne se répète plus d'une image à l'autre.

1.2 Fusion du dataset

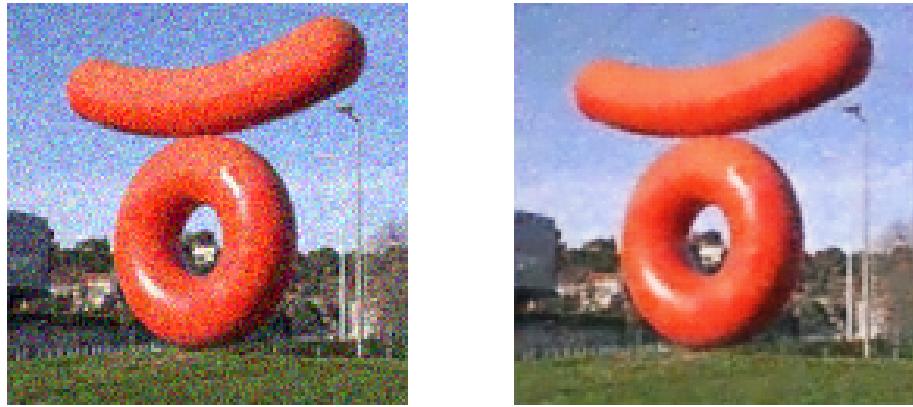
Pour que chacun des types de bruit puisse être pris en compte par notre modèle, il faut l'entraîner sur l'ensemble de ces différents types. Pour cela, nous avons numéroté les images de sorte à ce qu'une image clean corresponde à 8 bruits différents : Aléatoire, Poivre et sel, Gaussien, par Expansion et avec une intensité normale ou forte.



Fig. 3. – Résultats pour différents bruits et un training de 80 epochs. En haut : image bruitée, au milieu : image reconstruite et en bas : image clean.

Avec ce nouveau dataset, nous obtenons un PSNR constant d'environ 25dB. Les résultats sont moins bon qu'auparavant pour 2 raisons principales : le dataset inclut les bruits par expansion dynamique qui modifient grandement l'image d'origine et produisent des résultats équivalents à celui-ci pour un

training focalisé sur ce type de bruit particulier. Aussi, les bruits sont désormais différents à chaque image, donc le modèle n'apprend pas toujours le même bruit contrairement à ce que nous avions avant.



(a) Image d'entrée bruitée

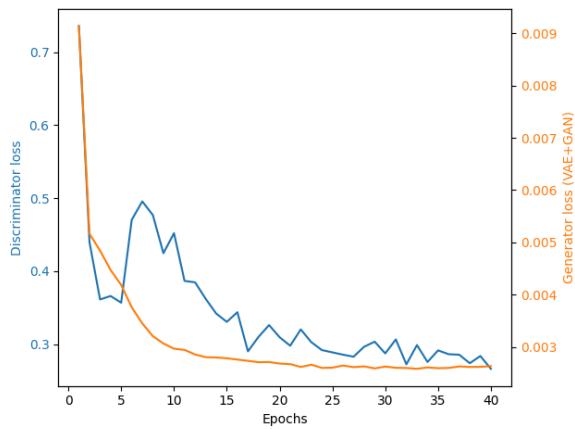
(b) Image de sortie débruitée

Fig. 4. – Exemple d'un débruitage d'image quelconque par notre modèle.

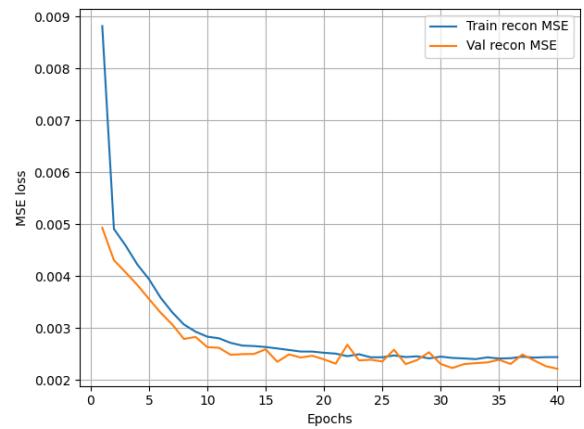
Nous produisons également un entraînement de 40 epochs sur une base de données de 1100/200 de ratio train/val sans bruit expand.



Fig. 5. – Résultats pour 40 epoch sans training expand.



(a) Loss discriminateur (bleu) & Loss VAE (orange)



(b) Loss total (VAE + discriminateur)

Fig. 6. – Courbes des résultats pour la configuration.

Celui-ci résulte en des PSNR constants au delà de 27dB et des images plus claires dans cette configuration.



(a) Image d'entrée bruitée

(b) Débruitage avec expand

(c) Débruitage sans expand

Fig. 7. – Comparaison d'un débruitage avec nos deux modèles.

2 Améliorations du GAN

En plus de la modification du base de données d'images, nous avons poursuivi l'exploration d'une approche Paired-based GAN, consistant à comparer non seulement la paire classique (clean / recon), mais surtout deux relations fondamentales :

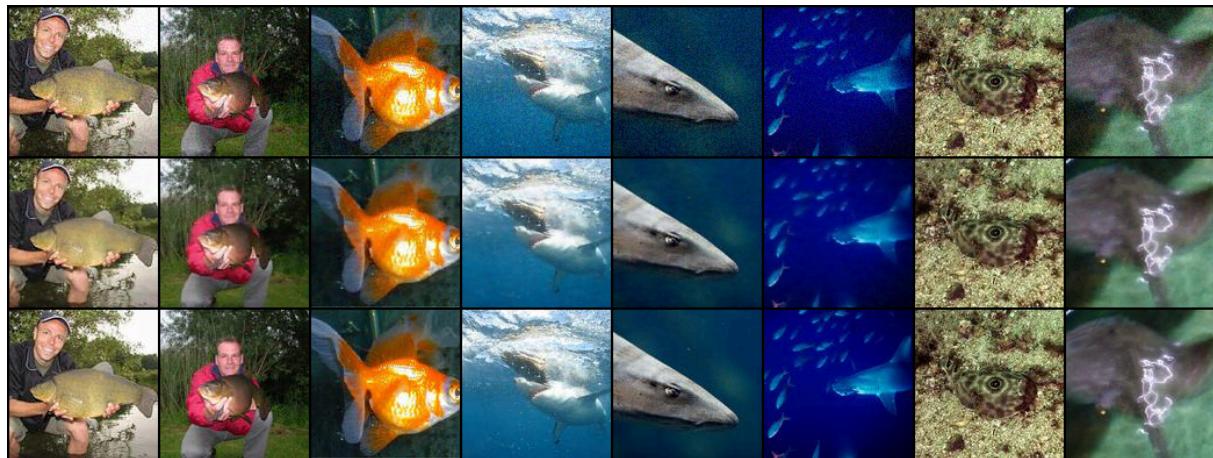
- Paire réelle : (*noisy, clean*) , qui représente la correspondance authentique entre une image bruitée et sa version propre.
- Paire générée : (*noisy, recon*)=(*noisy, noisy-noise_hat*) , dans notre architecture, le générateur ne produit pas directement une image propre. Il prédit d'abord le bruit sous la forme de *noise_hat*. La reconstruction s'obtient alors par une opération résiduelle : *recon=noisy-noise_hat*
- Avantages :
 - La tâche du modèle est de capturer la structure statistique du bruit, plutôt que de générer librement une image “propre” potentiellement incohérente avec l’entrée.
 - La prédiction du bruit est un espace d’apprentissage plus restreint.

Dans ce cadre, le discriminateur ne se contente plus d'estimer si une image reconstruite ressemble à une image propre. Il juge la relation entre les paires.

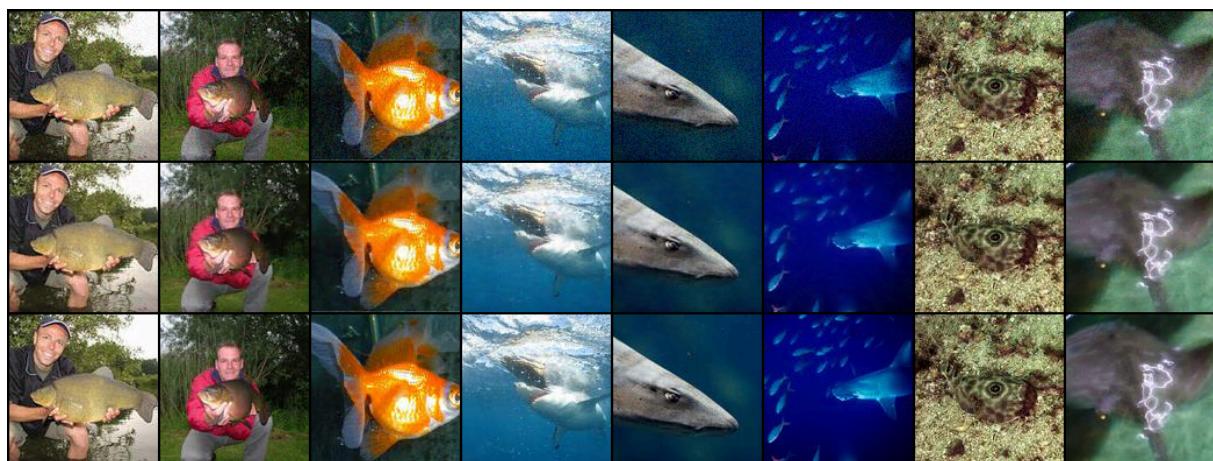
Cependant, même si cette approche est théoriquement fondée, les résultats expérimentaux montrent que les meilleures performances obtenues ne dépassent celles du VAE seul que d'environ 0,1 dB en PSNR. Ce gain reste insuffisant et ne répond pas à nos attentes.

2.1 Résultats

- With week random noise :
 - Pure vae : max psnr :33.933 dB
 - With GAN : max psnr : 34.04dB
- With strong gussian noise ($\sigma = 60$) :
 - Pure vae :max psnr :26.043 dB
 - With GAN : max psnr 26.131

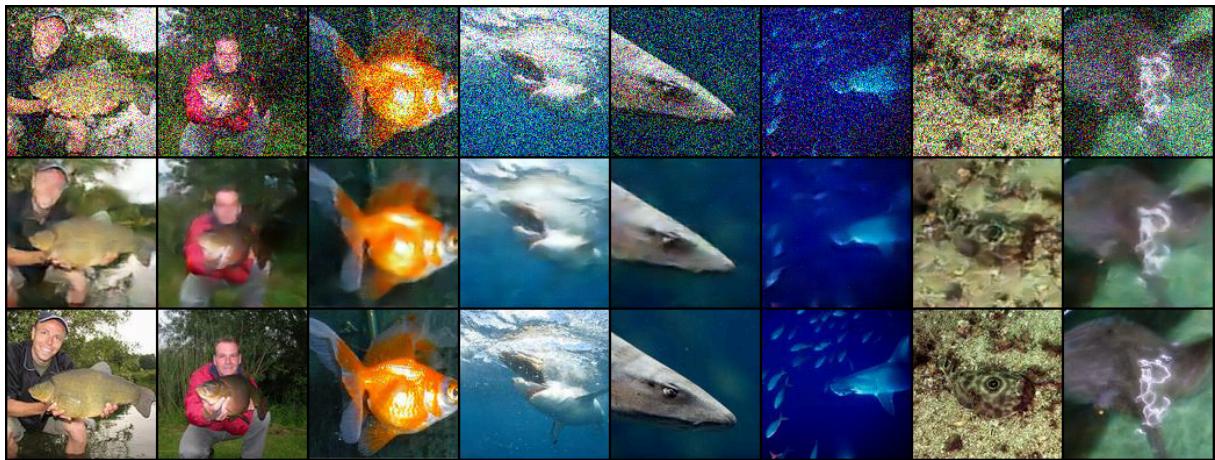


(a) Vae pur

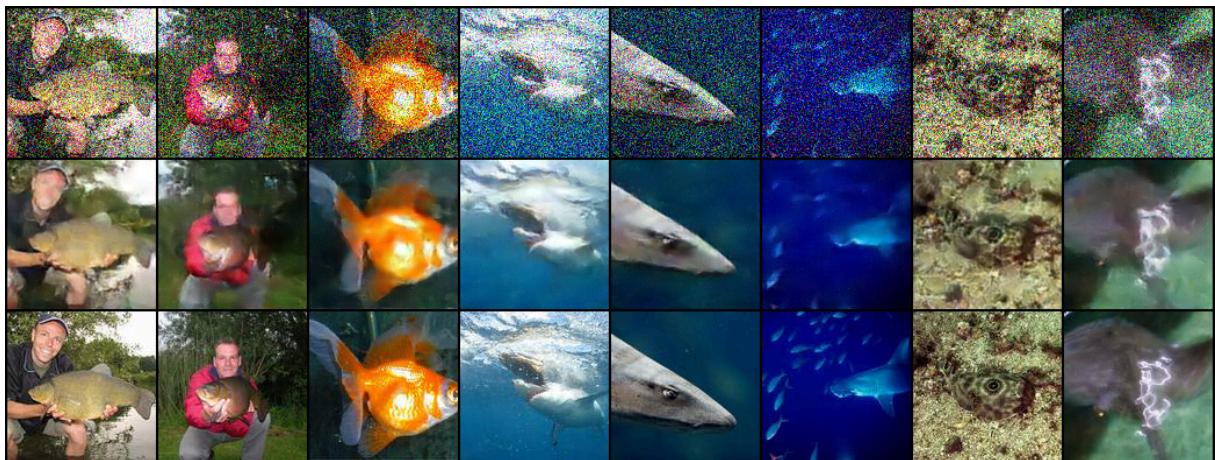


(b) VAE+GAN

Fig. 8. – Avec le bruit aléatoire faible



(a) Vae pur



(b) VAE+GAN

Fig. 9. – Avec le bruit gaussien fort